

Dự đoán Khả năng Sống sót Sau Thảm họa Titanic bằng Các Thuật toán Học Máy

Thành viên: Lê Đoàn Kim Ngân, Lê Thị Trúc Ly, Lâm Tú Nhi,
Nguyễn Đăng Khoa

Liên hệ : E-mail(s) : khoanguyen12062005@gmail.com;

Đồng tác giả: nhilam150@gmail.com;

imtrucly@gmail.com;

ledoankimngan2005@gmail.com;

Các tác giả đóng góp công bằng trong bài báo này.

Tóm tắt

Vào năm 1912, đã có một sự kiện hàng hải rung động cả thế giới được xem là thảm khốc nhất thế giới đó chính là thảm họa chìm tàu *RMS Titanic*, nó cũng đã cướp đi sinh mạng của hơn 1500 hành khách và thủy thủ có trên con tàu này. Trong nghiên cứu này, chúng ta sẽ xây dựng một mô hình học máy nhằm có thể dự đoán được khả năng sống sót của các hành khách dựa trên các đặc trưng nhân khẩu và thông tin hành khách như giới tính, tuổi, giá vé, hạng vé và điểm khởi hành. Dữ liệu được sử dụng lấy từ bộ dữ liệu công khai *Titanic - Machine Learning from Disaster* trên Kaggle. Bằng cách sử dụng các mô hình học máy như: *Logistic Regression*, *Random Forest*, *Support Vector Machine (SVM)*, *XGBosst*,... thông qua các quy trình như : *tiền xử lý dữ liệu*, *phân tích tương quan* giữa các đặc trưng, trích xuất và tạo thêm các đặc trưng (*feature engineering*). Huấn luyện và đánh giá các mô hình thông qua các thông số như: *Accuracy*, *F1-Score*, *ROC AUC*. Kết quả thực nghiệm cho thấy mô hình **SVM** có khả năng dự đoán chính xác nhất. Nghiên cứu này không chỉ góp phần minh họa ứng dụng của học máy trong khai thác dữ liệu lịch sử mà còn khẳng định tầm quan trọng của việc chọn lọc và xử lý đặc trưng phù hợp trong bài toán dự đoán nhị phân.

Từ khóa: Titanic, học máy, khai thác dữ liệu, dự đoán sống sót, dự đoán nhị phân.

1. Giới thiệu

Với hậu quả do thảm họa *Titanic* mang lại, dù đã trôi qua hơn một thế kỉ nhưng sự kiện này vẫn rất thu hút sự quan tâm từ giới nghiên cứu bởi dữ liệu của hành khách được lưu trữ đầy đủ và phản ánh rõ các mối quan hệ giữa các yếu tố về nhân khẩu học và khả năng sống sót. Trong thời đại 4.0, nơi mà dữ liệu và trí tuệ nhân tạo đang *phát triển* một cách vô cùng mạnh mẽ, việc áp dụng các mô hình học máy để *khai thác, phân tích* và *dự đoán* từ những bộ dữ liệu lịch sử như *Titanic* không chỉ mang lại ý nghĩa về *học thuật* mà còn giúp chúng ta minh họa được *khả năng ứng dụng* của các công nghệ trong việc nhận diện được các *yếu tố rủi ro* và *đưa ra quyết định*.

Trước đây, trong các cuộc nghiên cứu người ta chỉ sử dụng các phương pháp *thống kê truyền thống* hoặc chỉ là các mô hình học máy *cơ bản* như *Logistic Regression* để dự đoán *xác suất sống sót*. Tuy nhiên, với sự phát triển mạnh mẽ của máy học hiện nay, đã có rất nhiều thuật toán *tiên tiến* ra đời như: *Random Forest, Support Vector Machine (SVM), XGBoost*, ... đã chứng minh được khả năng xử lý được các loại *dữ liệu phi tuyến* và khai thác được các *đặc trưng phức tạp* tốt hơn. Dù là như vậy nhưng việc so sánh và đánh giá hiệu năng giữa các mô hình này vẫn còn *hạn chế* do các tiêu chí đánh giá *khác nhau* nên kết quả nghiên cứu *không thể so sánh trực tiếp* được.


Từ các *thực tế* đó, nghiên cứu này được hình thành và thực hiện nhằm mục đích xây dựng và *so sánh hiệu năng* của các mô hình học máy trong việc dự đoán được khả năng sống sót của các hành khách trên con tàu *Titanic*. Nghiên cứu này cần tập trung vào các quy trình *tiền xử lý dữ liệu, kỹ thuật tạo đặc trưng* (feature engineering) và *đánh giá* các mô hình bằng phương pháp *K-Fold Cross Validation*. Kết quả kỳ vọng sẽ xác định được mô hình nào *tối ưu* và làm rõ được *vai trò* của từng yếu tố trong việc ảnh hưởng đến khả năng sống sót, qua đó góp phần củng cố hiểu biết về *ứng dụng học máy* trong phân tích dữ liệu.

2. Đối tượng và phương pháp

2.1. Tập dữ liệu Titanic

Dựa trên tập dữ liệu về các thông tin của các hành khách đã có mặt trên con tàu *Titanic*. Với *10 biến số* và gần *1000 mẫu* quan sát, bộ dữ liệu được thiết kế nhằm phân biệt các hành khách còn *sống* và đã *chết*. Tuy nhiên, theo như phân tích của chúng tôi đã phát hiện ra một số khó khăn nhằn mạnh về *mức độ phức tạp* của nhiệm vụ này. Trước hết, dữ liệu bị *thiếu* ở các dòng nổi lên như một vấn đề đáng phải chú ý. Chúng tôi nhận thấy sự thiếu sót *ngghiêm trọng* này, với số lượng giá trị bị thiếu ở cột *Cabin* lên tới 687 dòng (gần *80% tổng số mẫu*) và cột *Age* cũng không hề ít khi bị thiếu 177 dòng (gần *20%*). Bên cạnh đó cột *Age* và *Fare* có các giá trị *outlier rất lớn*, những điều này đã tạo ra một trở ngại đáng

kể trong việc đào tạo mô hình của chúng tôi sao cho hiệu quả, vì sự chênh lệch này sẽ làm cho mô hình *thiên lệch* về các đặc trưng có giá trị lớn hơn. Việc này sẽ cản trở khả năng *học tập* của các mô hình. Hơn nữa, qua quá trình kiểm tra của chúng tôi đã nhận ra sự thiếu hụt về các mối tương quan giữa một số biến trong bộ dữ liệu. Việc thiếu các mối tương quan này đã làm phức tạp sự nỗ lực của chúng tôi trong việc xác định các mối quan hệ và cản trở *khả năng dự đoán* của mô hình.



Hình 1 : Phương pháp đề xuất tổng thể

Nghiên cứu này gặp phải những thách thức do các *missing value*, *outlier*, các mối tương quan khá ít cũng như tập dữ liệu nhỏ. Nhưng dữ liệu đã được chúng tôi *phân tích, tiền xử lý* nghiêm ngặt để *đảm bảo chất lượng* và *tính phù hợp* của dữ liệu với các mô hình học máy. Phương pháp này đã giúp *xử lý sự phức tạp* của tập dữ liệu và *phát triển* các phương pháp mạnh mẽ để có thể *phân loại* khả năng sống/chết một cách hiệu quả.

2.2. Tổng quan về vấn đề

Nghiên cứu về bài toán dự đoán khả năng sống sót trên tàu Titanic là một trong những hướng đi kinh điển trong lĩnh vực học máy, được sử dụng rộng rãi để đánh giá và so sánh hiệu quả của các thuật toán *phân loại nhị phân*. Trong các phương pháp học máy *truyền thống*, các mô hình như *Logistic Regression*, Cây quyết định (*Decision Tree*), và Rừng ngẫu nhiên (*Random Forest*) thường được sử dụng nhờ khả năng diễn giải cao và tính *đơn giản* trong triển khai. Tuy nhiên, các mô hình này đôi khi không thể mô tả đầy đủ mối quan hệ *phi tuyến* giữa các đặc trưng, đặc biệt khi các yếu tố nhân khẩu học, địa vị xã hội và mối quan hệ gia đình tương tác lẫn nhau một cách *phức tạp*.

Trong nghiên cứu này, mô hình *Support Vector Machine – SVM* được xác định là mô hình đạt hiệu suất cao nhất trong việc dự đoán khả năng sống sót của hành khách. *SVM* thể hiện ưu thế nhờ khả năng xây dựng *siêu phẳng (hyperplane)* tối ưu để phân tách hai lớp dữ liệu, đồng thời hoạt động hiệu quả ngay cả khi kích thước tập dữ liệu nhỏ. Bằng việc lựa chọn hàm *kernel* thích hợp (chẳng hạn *rbf* hoặc *polynomial*), *SVM* có thể học được *ranh giới phi tuyến*, giúp mô hình nắm bắt các tương tác phức tạp giữa các đặc trưng như *Age*,

Sex, Fare, Pclass, và Embarked. Kết quả huấn luyện cho thấy SVM không chỉ đạt độ chính xác (*accuracy*) cao mà còn giữ được sự cân bằng tốt giữa *precision* và *recall*, vượt trội so với các mô hình khác như *Logistic Regression, Random Forest* và *KNN*.

Bên cạnh đó, tập dữ liệu Titanic vẫn tồn tại một số *thách thức* cố hữu, bao gồm quy mô nhỏ (891 mẫu huấn luyện) và sự thiếu hụt ở các *đặc trưng quan trọng* như Age, Cabin và Embarked. Mặc dù tỷ lệ *sống sót* (38%) và không sống sót (62%) không tạo ra mất cân bằng nghiêm trọng, sự chênh lệch vừa phải này vẫn có thể gây *sai lệch* trong dự đoán nếu không được *xử lý cẩn thận*. Do đó, việc tiền xử lý dữ liệu, bao gồm *chuẩn hóa* (scaling), *mã hóa* (encoding), và *xử lý giá trị thiếu*, đóng vai trò quan trọng trong việc giúp mô hình SVM phát huy *hiệu quả tối đa*.

Từ những cơ sở trên, nghiên cứu tập trung xây dựng một quy trình huấn luyện toàn diện, kết hợp giữa tiền xử lý dữ liệu, chọn và tạo đặc trưng, và tối ưu tham số cho mô hình SVM nhằm đạt hiệu năng cao nhất. Cách tiếp cận này cho thấy rằng, với việc lựa chọn đặc trưng phù hợp và điều chỉnh tham số hợp lý, SVM là một trong những mô hình có độ ổn định và khả năng tổng quát hóa tốt nhất cho bài toán dự đoán khả năng sống sót trên tàu Titanic.

2.3. Mô hình đề xuất

Trong phần này, chúng ta sẽ liệt kê các đối tượng thử nghiệm của nghiên cứu bao gồm các mô hình học máy truyền thống như *Logistics Regression* và các mô hình tiên tiến hơn như *Random Forest, Support Vector Machine - SVM*. Sau đó chúng tôi sẽ tập trung vào phân tích chi tiết của từng nhóm mô hình học máy, làm rõ lý do tại sao chúng phù hợp với dữ liệu dạng bảng (tabular data), đồng thời thảo luận chuyên sâu về các kỹ thuật lấy mẫu và hàm mất mát được sử dụng.

Như đã đề cập trước đó, mô hình *Support Vector Machine – SVM* là một trong những phương pháp học máy nổi bật, đã đạt được nhiều thành tựu quan trọng trong các bài toán phân loại nhị phân và nhận dạng mẫu. SVM hoạt động dựa trên nguyên lý xác định siêu phẳng tối ưu để phân tách các lớp dữ liệu, đồng thời có khả năng xử lý tốt các mối quan hệ phi tuyến thông qua việc sử dụng các hàm nhân (kernel).

Trong nghiên cứu này, mô hình SVM được tinh chỉnh và tối ưu dựa trên hàm nhân Radial Basis Function (RBF), vốn được đánh giá là phù hợp cho dữ liệu có cấu trúc phi tuyến như tập dữ liệu Titanic. Các tham số điều chỉnh, bao gồm hệ số phạt (C) và tham số gamma (γ), được lựa chọn thông qua quá trình thử nghiệm và xác thực chéo để đạt hiệu suất cao nhất. Chúng tôi kỳ vọng rằng mô hình SVM được xây dựng và tối ưu theo hướng này sẽ mang lại kết quả tích cực, thể hiện khả năng phân loại ổn định và tổng quát hóa tốt trên tập

dữ liệu Titanic.

Phân tích chuyên sâu cho thấy việc lựa chọn mô hình phù hợp là chưa đủ; cần kết hợp với các kỹ thuật tiền xử lý và chọn đặc trưng để đạt hiệu quả tối ưu. Trong nghiên cứu này, dữ liệu được chuẩn hóa bằng StandardScaler, mã hóa bằng One-Hot Encoding và mở rộng với các đặc trưng như FamilySize, IsAlone và Title có thể giúp các mô hình đạt hiệu suất ổn định và chính xác hơn.

Hơn nữa, chúng tôi cho rằng việc lựa chọn tiêu chí đánh giá và chiến lược tối ưu hóa phù hợp có thể cải thiện đáng kể khả năng dự đoán của mô các hình. Các nghiên cứu trước đây đã chỉ ra rằng việc sử dụng các chỉ số đánh giá cân bằng như F1-score và ROC-AUC giúp phản ánh chính xác hơn hiệu năng của mô hình trên dữ liệu có sự chênh lệch giữa các lớp.

Bằng cách triển khai các chiến lược này, chúng tôi hướng tới việc tăng cường khả năng xử lý dữ liệu bảng bị mất cân bằng và cải thiện hiệu năng tổng thể của mô hình trong bài toán dự đoán khả năng sống sót.

2.4. Chi tiết triển khai

Nghiên cứu này tập trung khảo sát và so sánh ba mô hình học máy phổ biến, bao gồm Hồi quy Logistic (Logistic Regression), Rừng ngẫu nhiên (Random Forest) và Máy véc-tơ hỗ trợ (Support Vector Machine – SVM), nhằm đánh giá hiệu quả của chúng trong việc dự đoán khả năng sống sót của hành khách trên tàu Titanic.


Mô hình Logistic Regression: Là một trong những mô hình cơ bản và dễ diễn giải nhất trong học máy, hồi quy logistic được sử dụng rộng rãi cho các bài toán phân loại nhị phân. Mô hình này hoạt động dựa trên việc ước lượng xác suất sống sót của hành khách thông qua hàm logistic (sigmoid). Trong nghiên cứu này, hồi quy logistic được sử dụng như mô hình cơ sở (baseline) để đánh giá mức độ ảnh hưởng của các đặc trưng đã được tiền xử lý, đồng thời so sánh hiệu năng với các mô hình phi tuyến tính phức tạp hơn.

Mô hình Random Forest: Random Forest là một thuật toán học máy mạnh mẽ dựa trên tập hợp nhiều cây quyết định (decision trees). Mỗi cây được huấn luyện trên một mẫu ngẫu nhiên của dữ liệu, và kết quả cuối cùng được xác định bằng biểu quyết đa số (majority voting). Mô hình này có khả năng xử lý tốt dữ liệu chứa nhiễu, hạn chế hiện tượng quá khớp (overfitting) và cung cấp khả năng đánh giá tầm quan trọng của từng đặc trưng. Trong bài toán Titanic, Random Forest được sử dụng nhằm kiểm tra khả năng nắm bắt mối quan hệ phi tuyến giữa các yếu tố như độ tuổi, giới tính, hạng ghế và mức giá vé đối với xác suất sống sót.

Mô hình Support Vector Machine (SVM): SVM là một trong những thuật toán học máy mạnh mẽ nhất cho các bài toán *phân loại*. Mô hình này xác định *siêu phẳng tối ưu* (*optimal hyperplane*) để phân tách hai lớp dữ liệu với khoảng cách biên lớn nhất. Để xử lý các mối quan hệ phi tuyến trong dữ liệu Titanic, nghiên cứu này sử dụng hàm nhân *Radial Basis Function (rbf)* cùng với quá trình *tối ưu tham số (C và γ)* thông qua *Grid Search* và *K-Fold Cross Validation*. Nhờ khả năng tạo ranh giới phân tách *linh hoạt* và *ổn định*, SVM được kỳ vọng đạt hiệu năng *cao nhất* trong việc dự đoán khả năng sống sót của hành khách.

Bên cạnh việc xử lý dữ liệu thông qua các kỹ thuật tiền xử lý và chọn đặc trưng, chúng tôi nhận thấy rằng việc lựa chọn các tiêu chí đánh giá và chiến lược tối ưu hóa phù hợp có thể giúp cải thiện đáng kể hiệu năng của mô hình. Do đó, nghiên cứu này tiến hành thử nghiệm và so sánh nhiều phương pháp đánh giá khác nhau nhằm xác định cách tiếp cận chính xác và khách quan nhất trong việc dự đoán khả năng sống sót của hành khách trên tàu Titanic.

F1-Score: Chỉ số này được sử dụng để đánh giá độ cân bằng giữa precision (độ chính xác) và recall (độ bao phủ). Trong các bài toán có chênh lệch giữa hai lớp, như tỷ lệ sống sót và không sống sót trong tập dữ liệu Titanic, việc tối ưu hóa F1-score giúp mô hình tránh thiên lệch về một lớp, đặc biệt khi một chỉ số có xu hướng bị bỏ qua nếu chỉ dựa vào độ chính xác thông thường. Trong đó: *TP* (True Positive) và *FP* (False Positive) là các mẫu dự đoán đúng hoặc sai theo thực tế các trường hợp dương, ngược lại *TN* (True Negative) và *FN* (False Negative) là các mẫu có dự đoán đúng hoặc sai theo thực tế các trường hợp âm. Dựa vào bốn thông số trên ta tính được *độ chính xác của các dự đoán dương tính* (Precision) và *khả năng phát hiện đúng các mẫu dương tính* (Recall). Nhưng chỉ dựa vào hai thông số trên để đánh giá thì chưa đủ, dễ đưa ra các nhận định sai lệch về chất lượng thật sự của mô hình. Và từ đó F1-Score ra đời để bù đắp vào thiếu hụt về đánh giá do hai mô hình này chưa cung cấp đủ.




Hình 2: Minh họa giữa Precision và Recall trong phân loại nhị phân

Nhưng chỉ dựa vào hai thông số trên để đánh giá thì chưa đủ, dễ đưa ra các nhận định sai lệch về chất lượng thật sự của mô hình. Và từ đó F1-Score ra đời để bù đắp vào thiếu hụt về đánh giá do hai mô hình này chưa cung cấp đủ.

$$F1 = \frac{2 \times (\text{Precision} \times \text{Recall})}{\text{Precision} + \text{Recall}} \quad (1)$$

ROC-AUC: Là thước đo khả năng phân biệt giữa hai lớp, chỉ số ROC-AUC phản ánh mức độ mô hình có thể xếp hạng các mẫu dương và âm chính xác. Trong nghiên cứu

này, ROC-AUC được xem như một tiêu chí quan trọng để đánh giá tổng thể hiệu năng của các mô hình học máy, đặc biệt trong bối cảnh dữ liệu có sự chênh lệch lớp vừa phải.




Trong quá trình thí nghiệm, việc các giá trị có sự chênh lệch lớn sẽ không tốt cho việc huấn luyện của chúng ta nếu mô hình chúng ta sử dụng là các loại mô hình như SVM, Logistic Regression,... chúng sẽ dẫn đến quá trình hội tụ chậm hoặc mô hình bị thiên lệch về phía đặc trưng có giá trị lớn. Để khắc phục vấn đề này ta cần xử lý các dữ liệu sao cho giá trị của chúng được đưa về cùng một thang đo. Một trong những phương pháp phổ biến và hiệu quả nhất để giải quyết vấn đề này là *chuẩn hóa dữ liệu (Data Standardization)*. Mục tiêu của quá trình này là điều chỉnh các đặc trưng (features) về cùng một thang đo, giúp mô hình học máy có thể đánh giá mức độ ảnh hưởng của từng biến một cách công bằng. Việc chuẩn hóa đặc biệt quan trọng đối với những thuật toán *dựa trên khoảng cách hoặc độ lớn của tham số*, chẳng hạn như *Support Vector Machine (SVM)*, *Logistic Regression*, hay *K-Nearest Neighbors (KNN)*.

Bên cạnh quá trình chuẩn hóa, việc *mã hóa dữ liệu phân loại (categorical encoding)* cũng đóng vai trò quan trọng nhằm giúp mô hình học máy có thể hiểu và xử lý các biến không phải dạng số. Nhiều đặc trưng trong tập dữ liệu thường mang giá trị định danh hoặc nhãn (ví dụ: giới tính, hạng vé, nơi khởi hành, v.v.), vốn không thể được mô hình diễn giải trực tiếp nếu chưa được chuyển đổi sang dạng số học. Hiện nay, có nhiều phương pháp mã hóa khác nhau, tùy thuộc vào đặc điểm của dữ liệu và yêu cầu của mô hình mà có hai loại mã hóa phổ biến nhất là: *Label Encoding* (chuyển đổi mỗi nhãn thành một giá trị số duy nhất (0, 1, 2, ...)) và *One-Hot Encoding* (biến mỗi nhãn thành một vector nhị phân, trong đó chỉ có một phần tử mang giá trị 1 tương ứng với nhãn gốc).

Trong quá trình xây dựng mô hình học máy, việc xử lý dữ liệu và huấn luyện mô hình thường bao gồm nhiều bước liên tiếp như làm sạch dữ liệu, xử lý giá trị thiếu, mã hóa biến phân loại, chuẩn hóa đặc trưng, và cuối cùng là huấn luyện mô hình. Tuy nhiên, nếu các bước này được thực hiện thủ công và tách rời, quá trình sẽ dễ xảy ra sai sót và khó tái sử dụng. Để giải quyết vấn đề đó, *Pipeline* (đường dẫn xử lý dữ liệu) được sử dụng như một *cấu trúc tự động hóa* giúp liên kết tuần tự các bước xử lý dữ liệu và huấn luyện mô hình trong cùng một quy trình. Mỗi bước trong Pipeline được thực hiện tuần tự theo thứ tự định nghĩa trước, đảm bảo *tính thống nhất* giữa tập huấn luyện và tập kiểm thử, đồng thời *loại bỏ khả năng rò rỉ dữ liệu (data leakage)*. Cụ thể, trong nghiên cứu này Pipeline được xây dựng gồm hai phần chính: Tiền xử lý dữ liệu (bao gồm điền giá trị khuyết thiếu, chuẩn hóa và mã hóa biến phân loại) huấn luyện mô hình. Việc sử dụng Pipeline giúp đảm bảo rằng mọi biến đổi dữ liệu được *áp dụng nhất quán* trên cả tập huấn luyện và tập kiểm thử, đồng thời hỗ trợ dễ dàng tích hợp với các phương pháp tối ưu tham số như *Grid Search* trong quá trình tối ưu mô hình.

Grid Search & Cross Validation: Để đảm bảo khả năng tổng quát hóa của mô hình, chúng tôi sử dụng kỹ thuật Grid Search kết hợp với K-Fold Cross Validation nhằm tìm ra bộ siêu tham số tối ưu cho từng mô hình. Phương pháp này cho phép mô hình được đánh giá trên nhiều tập con khác nhau, giảm thiểu rủi ro quá khớp và cải thiện độ tin cậy của kết quả.

$$Score_{final} = \frac{1}{K} \sum_{i=1}^K Score_i \quad (3)$$



Hình 4: Mô hình kết hợp giữa Grid search và phương pháp K-Fold Cross Validation

Model Optimization: Quá trình tối ưu được thực hiện cho ba mô hình chính, bao gồm điều chỉnh hệ số phạt (C) và tham số γ trong SVM, số lượng cây (n_estimators) và độ sâu (max_depth) trong Random Forest, cũng như phương pháp điều chuẩn (regularization) trong Logistic Regression. Việc tối ưu đồng bộ này cho phép đánh giá khách quan mức độ hiệu quả của từng thuật toán và xác định mô hình có khả năng dự đoán cao nhất.

3. Thí nghiệm và kết quả

3.1. Thiết lập thí nghiệm

Quy trình huấn luyện: Tập dữ liệu train được huấn luyện bằng kỹ thuật *K-Fold Cross Validation* (với $K = 10$) nhằm đảm bảo tính *khách quan* và giảm thiểu hiện tượng *quá khớp*. Phương pháp này cho phép mô hình được huấn luyện và kiểm thử luân phiên trên nhiều tập con khác nhau, từ đó cung cấp đánh giá *ổn định* và toàn diện hơn về *hiệu năng* mô hình.

Trước khi huấn luyện, toàn bộ dữ liệu được xử lý theo các bước đã trình bày, bao gồm *xử lý giá trị khuyết*, chuẩn hóa bằng *StandardScaler* và mã hóa các biến phân loại bằng *One-Hot Encoding* hoặc *Label Encoding*. Ngoài ra, các đặc trưng mở rộng như *FamilySize*, *IsAlone* và *Title* cũng được bổ sung nhằm tăng khả năng mô hình hóa mối *quan hệ phi tuyến* giữa các yếu tố.

Trong quá trình huấn luyện, các mô hình *Logistic Regression*, *Random Forest* và *Support Vector Machine (SVM)* được tối ưu hóa thông qua *Grid Search* kết hợp với *K-Fold Cross Validation* để lựa chọn bộ siêu tham số *tối ưu*. Các chỉ số đánh giá cân bằng như *F1-score* và *ROC-AUC* được sử dụng thay cho độ chính xác (*accuracy*) truyền thống, nhằm phản ánh tốt hơn khả năng *phân loại* giữa hai lớp (sống sót và không sống sót).

3.2. Phân tích và biến đổi dữ liệu

3.2.1. Xử lý cơ bản các missing value

Nhận thấy trường *Age*, *Cabin* và *Embarked* hiện đang thiếu dữ liệu, tiến hành xử lý ba trường dữ liệu này. Do trường dữ liệu *Cabin* thiếu quá nhiều ($\approx 77\%$ tổng số mẫu) nên ta tiến hành xóa bỏ nó ra khỏi bộ dữ liệu. Còn cột *Age* có số mẫu bị thiếu khá tương đối ($\approx 20\%$ tổng số mẫu) nên tại các vị trí *NaN* tiến hành thêm các giá trị trung vị (*median*) của cột *Age*.

Data columns (total 12 columns):			
#	Column	Non-Null Count	Dtype
0	PassengerId	891 non-null	int64
1	Survived	891 non-null	int64
2	Pclass	891 non-null	int64
3	Name	891 non-null	object
4	Sex	891 non-null	object
5	Age	714 non-null	float64
6	SibSp	891 non-null	int64
7	Parch	891 non-null	int64
8	Ticket	891 non-null	object
9	Fare	891 non-null	float64
10	Cabin	204 non-null	object
11	Embarked	889 non-null	object

	Missing Values	Percent (%)
Cabin	687	77.10
Age	177	19.87
Embarked	2	0.22

Bên cạnh đó trường *Embarked* chỉ thiếu 2 mẫu (rất ít), chỉ cần điền giá trị xuất hiện nhiều nhất (*mode*) của cột *Embarked*.


Có một điều đặc biệt nếu không thận trọng quan sát có thể không phát hiện đó là dữ liệu thiếu trong tập test có thêm cột “*Fare*”. Trong tập test.csv có thể quan sát được tuy chỉ có một mẫu bị thiếu nhưng nếu không xử lý sẽ gây ảnh hưởng đến việc huấn luyện các mô hình học máy của chúng ta. Trong trường hợp này ta có thể xử lý bằng cách điền giá trị trung vị (*median*) của cột “*Fare*” vào mẫu thiếu này.

Data columns (total 11 columns):				
#	Column	Non-Null Count	Dtype	
0	PassengerId	418 non-null	int64	
1	Pclass	418 non-null	int64	
2	Name	418 non-null	object	
3	Sex	418 non-null	object	
4	Age	332 non-null	float64	
5	SibSp	418 non-null	int64	
6	Parch	418 non-null	int64	
7	Ticket	418 non-null	object	
8	Fare	417 non-null	float64	
9	Cabin	91 non-null	object	
10	Embarked	418 non-null	object	

dtypes: float64(2), int64(4), object(5)

3.2.2. Phân tích đơn biến

Để có thể có góc nhìn rõ hơn về các trường trong bộ dữ liệu, ta cần tiến hành phân tích từng biến để hiểu rõ đặc điểm của các biến đơn lẻ để hiểu rõ hơn về dữ liệu ban đầu, phát hiện dữ liệu bất thường, chọn phương pháp xử lý cho từng biến cũng như chuẩn bị cho bước phân tích đa biến tiếp theo. Tôi sẽ thể hiện dữ liệu thông qua các biểu đồ Histogram để trực quan hóa hơn và dễ dàng cho việc phân tích.



Hình 5: Biểu đồ Histogram biểu diễn các trường dữ liệu cần quan sát

Từ biểu đồ trên ta quan sát được biến Age phân bố gần như chuẩn, tập trung chủ yếu từ khoảng 20-40 tuổi, bên cạnh đó cũng có một số hành khách nhỏ tuổi (<10) và lớn hơn 60. Từ đó có thể nhận thấy biến Age liên tục, phân bố hơi lệch phải, có thể chuẩn hóa nếu cần cho mô hình.

Tiếp theo là đến giới tính (Sex), đây là biến rời rạc nhị phân, chỉ gồm hai giá trị là Male và Female. Quan sát ta có thể thấy rõ ràng số lượng nam (Male) nhiều hơn nữ (Female) rõ rệt (gần gấp đôi). Tỷ lệ ở cột giới tính (Sex) mất cân đối thể này có thể ảnh hưởng đến khả năng sống sót (vì Titanic ưu tiên phụ nữ và trẻ em). Có thể dùng phương pháp onehot hoặc label-encoder để xử lý loại dữ liệu này.

Hạng vé cũng là một biến đáng quan tâm, biểu đồ cho ta thấy hành khách ở hạng 3 là đông nhất, tiếp đến là hạng 1 và 2. Điều này phản ánh cho ta thấy đa phần hành khách trên tàu thuộc tầng lớp trung lưu và lao động. Hạng vé cho ta biết được vị trí khoang tàu, điều này có ảnh hưởng trực tiếp đến khả năng tiếp cận thuyền cứu sinh trong trường hợp khẩn cấp.

Giữa việc có người thân và một mình cũng gây ra chút ảnh hưởng đến khả năng sống sót của một người. Hai biến “*SibSp*” và “*Parch*” thể hiện số người thân đi cùng (anh chị em, cha mẹ, con cái, vợ chồng). Ở đây có thể thấy được ở cả 2 biểu đồ về “*SibSp*” và “*Parch*” đều có tần suất giá trị 0 rất cao, thể hiện đa số hành khách đi một mình.


Có thể thấy giá vé (*Fare*) lệch phải một cách rõ rệt, phần lớn hành khách đều có giá vé dưới 50 đơn vị, trong khi đó thì có một số hành khách lại có giá vé cao vượt trội.

Phần lớn Embarked có tần suất giá trị là S, chiếm khoảng 72%, hai giá trị C và Q chiếm phần còn lại nhưng không quá đáng kể. Sự khác biệt này có thể liên kết với các thuộc tính khác như giá vé hạng vé để xử lý được tốt hơn. Trong trường hợp này sử dụng phương pháp onehot hoặc label là khả thi nhất để biến đổi dữ liệu phù hợp cho việc huấn luyện.

Ngoài biểu đồ Histogram, để có thể nhận biết và phát hiện các giá trị ngoại lai (outlier) ta còn có thể sử dụng các biểu đồ BoxPlot để làm điều này (Hình 6).

Ở phần này có thể quan sát được 2 cột dữ liệu có các giá trị ngoại lệ rõ ràng nhất chính là “*Age*” và “*Fare*”. Ở cột Age có trung vị khoảng tầm 28 tuổi, phân bố lệch phải vì phần râu trên dài hơn và cũng có một số ngoại lệ từ khoảng 60 đến tầm 80 tuổi. Ở biểu đồ BoxPlot biểu diễn biến *Fare*, có thể quan sát thấy rằng mặc dù giá trị trung vị chỉ nằm trong khoảng 15–30, nhưng lại tồn tại nhiều ngoại lệ với giá trị rất cao, dao động từ 300 đến trên 500. Sự chênh lệch lớn này tạo nên sự mất cân đối trong dữ liệu, có thể dẫn đến việc mô hình học máy ưu tiên các giá trị lớn hơn, gây sai lệch trong quá trình huấn luyện.


Để khắc phục hiện tượng này, cần áp dụng các phương pháp **chuẩn hóa dữ liệu** như *MinMaxScaler*, *StandardScaler* hoặc *RobustScaler* nhằm đưa các đặc trưng về cùng một thang đo, giúp mô hình học máy hoạt động ổn định và công bằng hơn giữa các biến.



Hình 6: Biểu đồ BoxPlot biểu diễn các dữ liệu số

3.2.3. Phân tích đa biến

Phân trước ta đã được tìm hiểu rõ về các đơn biến (đặc tính, giá trị, sự phân bố, outlier, ...), nhưng chỉ biết và hiểu về các đơn biến độc lập là chưa đủ để có thể giải quyết được vấn đề. Chính vì thế trong phần tiếp theo này ta sẽ đi đến tìm hiểu và phân tích đa biến đối với bài toán. Để dễ dàng hơn trong việc phân tích đa biến, ta sử dụng biểu đồ tương quan giữa các biến ở bên dưới để dễ quan sát hơn(Hình 7).




Hình 7: Ma trận tương quan giữa các biến số

Các số trong biểu đồ trên được gọi là hệ số tương quan để đo lường mối quan hệ tuyến tính giữa hai biến số, được tính theo công thức:


$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

Trong đó, r_{xy} là hệ số tương quan giữa hai biến x và y ; $\bar{x}$, $\bar{y}$ lần lượt là giá trị trung bình của hai biến; giá trị $r_{xy} \in [-1; 1]$. Nếu $r > 0$ gọi là tương quan dương, ngược lại gọi là tương quan âm và $|r|$ càng lớn thì mối tương quan giữa hai biến số càng mạnh.

Từ lý giải cơ bản trên về hệ số tương quan và ma trận tương quan (Hình 7) ta có thể đưa ra một số nhận xét cho mối quan hệ giữa các biến trong ma trận. Trước tiên là mối tương quan giữa các đơn biến (*Age*, *Sex*, *Fare*) với biến mục tiêu (*Survived*). Dễ dàng nhận thấy biến giới tính (*Sex*) có độ tương quan cao nhất đối với *Survived* ($r = 0.54$), điều này cho thấy giới tính là yếu tố vô cùng quan trọng trong việc xác định khả năng sống sót. Cụ thể, những hành khách nữ có xác suất sống cao hơn đáng kể so với các hành khách nam (Hình 8). Tiếp đến là giá vé (*Fare*) cũng có tương quan dương nhẹ với *Survived* (≈ 0.26) cho thấy hành khách trả giá vé cao hơn thường thuộc tầng lớp thượng lưu, có khả năng sống sót cao hơn (Hình 9).




Hình 8: Biểu đồ giữa Sex và Survived



thấy những biến này không phải là yếu tố quyết định lớn đối với khả năng sống sót, mặc dù thực tế trẻ nhỏ luôn được ưu tiên cứu hộ trước.

Ngoài việc xem xét mối tương quan giữa các biến độc lập với biến mục tiêu (Survived), việc phân tích mối tương quan giữa chính các biến độc lập cũng đóng vai trò quan trọng. Những mối quan hệ này có thể tiết lộ hiện tượng đa cộng tuyến hoặc gợi mở các đặc trưng kết hợp tiềm năng, giúp cải thiện hiệu quả của mô hình dự đoán. Khi xem xét ma trận tương quan giữa các biến độc lập, có thể nhận thấy một số mối liên hệ đáng chú ý. Pclass và Fare có tương quan âm rõ rệt, phản ánh thực tế rằng hành khách ở hạng vé cao thường trả giá vé thấp hơn, do hạng vé càng lớn thì điều kiện chỗ ngồi càng kém. SibSp và Parch thể hiện tương quan dương vừa phải, cho thấy xu hướng hành khách đi cùng người thân trong cùng nhóm gia đình. Ngoài ra, Age và Pclass có tương quan âm nhẹ, gợi ý rằng hành khách lớn tuổi thường mua vé ở hạng cao hơn. Những mối quan hệ này giúp nhận diện khả năng đa cộng tuyến giữa các biến, đồng thời gợi ý việc tạo ra các đặc trưng kết hợp như FamilySize nhằm cải thiện hiệu quả mô hình dự đoán.

Hạng vé (Pclass) tuy có mối tương quan âm, nhưng cũng không quá thấp ($r \approx -0.34$). Hệ số âm này cho thấy với những hành khách có hạng vé càng cao (Pclass = 1) thì tỉ lệ sống sót của họ sẽ cao hơn những người có hạng vé thấp (Pclass = 3) (Hình 10). Các đơn biến còn lại như Age, SibSp, ... có tương quan rất yếu với Survived. Cho ta



3.2.4. Feature Engineering

Việc cải thiện khả năng học của mô hình chỉ dựa trên các trường dữ liệu gốc là điều gần như không khả thi. Để nâng cao hiệu quả huấn luyện, cần tiến hành *trích xuất và kết hợp các thuộc tính có mối quan hệ tiềm ẩn* nhằm tạo ra các *đặc trưng mới (feature engineering)* giúp mô hình học tốt hơn. Trong nghiên cứu này, chúng tôi đã xây dựng thêm một số đặc trưng mở rộng có khả năng gia tăng hiệu suất dự đoán của mô hình, bao gồm: *Title*, *IsFemale*, *FamilySize*, *IsChild*, *IsMother*, *HasBin*, *Age*Pclass*, *Deck*, *Fare_Pclass*, và *TicketPrefix*.

Cụ thể, đặc trưng *Title* được trích xuất từ trường *Name* nhằm phản ánh chức danh, giới tính, độ tuổi của hành khách, yếu tố này có liên quan đến khả năng được ưu tiên cứu hộ.

IsFemale được xây dựng từ trường **Sex**, biểu thị giới tính nữ, vốn là một yếu tố có ảnh hưởng đáng kể đến khả năng sống sót.

FamilySize được tính bằng tổng số anh chị em (*SibSp*) và cha mẹ hoặc con cái (*Parch*) đi cùng, cộng thêm một, thể hiện quy mô gia đình. Đặc trưng này giúp mô hình nhận biết liệu hành khách đi một mình hay đi cùng người thân, từ đó nắm bắt các yếu tố hành vi trong quá trình thoát nạn. *IsChild* là biến nhị phân xác định những hành khách dưới 12 tuổi, đại diện cho nhóm đối tượng trẻ em thường được ưu tiên trong cứu hộ. Bên cạnh đó, *IsMother* được định nghĩa cho những hành khách nữ, có *Parch* > 0, lớn hơn 18 tuổi và có chức danh trong tên là *Mrs*, phản ánh vai trò xã hội có thể ảnh hưởng đến hành vi và quyết định của họ trong tình huống khẩn cấp.

Ngoài ra, *HasBin* là đặc trưng cho biết hành khách có thông tin *Cabin* hay không, từ đó gián tiếp thể hiện mức độ giàu có hoặc vị trí hạng vé cao. *Deck* được suy ra từ ký tự đầu của *Cabin*, cho biết khu vực sinh hoạt trên tàu và có thể liên quan đến khả năng tiếp cận thuyền cứu hộ. Đặc trưng *Age*Pclass* được xây dựng bằng cách nhân giữa tuổi và hạng vé, biểu diễn mối tương tác phi tuyến giữa độ tuổi và điều kiện kinh tế của hành khách.

Cuối cùng, *Fare_Pclass* được tính bằng tỷ lệ giữa *Fare* và *Pclass*, nhằm chuẩn hóa giá vé theo hạng vé để mô hình nhận diện tốt hơn chênh lệch giá trị kinh tế giữa các nhóm hành khách. Trong khi đó, *TicketPrefix* được trích xuất từ phần chữ của mã *Ticket*, phản ánh nguồn gốc hoặc nhóm mua vé, yếu tố đôi khi có liên quan đến vị trí hoặc ưu tiên khi sơ tán.


3.2.5. Chuẩn hóa và mã hóa dữ liệu

Ngoài việc xây dựng thêm một số đặc trưng mới, chuẩn hóa dữ liệu cũng là một khâu vô cùng quan trọng để có thể giúp cho mô hình học tốt hơn. Có khá nhiều cách để chuẩn hóa dữ liệu như *MinMaxScaler*, *StandardScaler*, *RobustScaling*, *MaxAbsScaler*, *Normalizer*, ... Ở nghiên cứu này chúng ta sẽ tiến hành chuẩn hóa dữ liệu theo phương pháp *StandardScaler*, đây là kỹ thuật được sử dụng rộng rãi nhất hiện nay. Phương pháp này thực hiện chuẩn hóa theo phân phối chuẩn, đưa mỗi đặc trưng của nó về dạng trung bình bằng 0 và độ lệch bằng 1, theo công thức:
$$x' = \frac{x - \mu}{\sigma}$$
Trong đó: x là giá trị gốc của đặc trưng, μ là giá trị trung bình của đặc trưng đó, σ là độ lệch chuẩn tương ứng. Các đặc trưng cần chuẩn hóa dữ liệu hiện tại là: *Age*, *Fare*, *FamilySize*, *Fare_Pclass*, *Age*Pclass*.

Ngoài việc chuẩn hóa ta cũng cần mã hóa các dữ liệu để mô hình đạt được hiệu suất tối ưu hơn. Nếu chuẩn hóa dữ liệu là xử lý các đặc trưng dạng số thì mã hóa dữ liệu là phân loại các đặc trưng không phải dạng số để mô hình có thể hiểu và xử lý được. Các kỹ thuật được dùng để mã hóa như *Label Encoding* hoặc *One-Hot Encoding* sẽ được áp dụng tùy theo đặc điểm của từng mô hình và dạng dữ liệu. Ở thí nghiệm này chúng ta sẽ xử lý các đặc

trung bằng kỹ thuật One-Hot Encoding với các đặc trưng cần xử lý là : *Pclass*, *Sex*, *Embarked*, *Title*, *IsChild*, *IsMother*, *Deck*, *HasCabin*, *TicketPrefix*.

Nhưng việc xử lý chuẩn hóa hoặc mã hóa đơn lẻ từng đặc trưng sẽ gây rối hơn dẫn đến việc dễ sai lầm. Thay vào đó, ta sử dụng kỹ thuật *Pipeline* để có thể *tự động hóa và thống nhất toàn bộ quy trình xử lý dữ liệu*. Pipeline cho phép gộp tất cả các bước như chuẩn hóa, mã hóa, và huấn luyện mô hình vào cùng một cấu trúc liên mạch. Khi đó, dữ liệu sẽ được truyền qua từng giai đoạn xử lý theo đúng thứ tự định sẵn, đảm bảo tính đồng nhất giữa quá trình huấn luyện và dự đoán. Việc này không chỉ giúp giảm thiểu rủi ro sai lệch do xử lý thủ công mà còn giúp dễ dàng tái sử dụng hoặc mở rộng quy trình cho các thí nghiệm khác.



Hình 11: Sơ đồ Pipeline tiền xử lý các đặc trưng

3.3. Kết quả

Chúng tôi đã thực hiện phương pháp K-Fold Cross Validation, sau đó tiến hành phân tích hiệu suất của mô hình thông qua các chỉ số đã đề cập gồm: độ chính xác (Accuracy), điểm F1 (F1-Score) và đường cong AUC (AUC Curve). Từ đó đánh giá được hiệu suất của các mô hình.

Với lần đầu tiên thử nghiệm bằng cách chỉ thực hiện xử lý các missing value cơ bản các đặc trưng còn thiếu dữ liệu như *Age*, *Embarked*, *Fare* cùng với việc chuẩn hóa cột *Age*, *Fare* để đưa về cùng thang đo giá trị và mã hóa cột *Sex*, *Embarked*. Sau khi tiền xử lý dữ liệu ta sẽ còn các đặc trưng được huấn luyện là : *Pclass*, *Age*, *Sex*, *Fare*, *Embarked*, *SibSp*, *Parch*. Ta được bảng kết quả như sau:

Bảng 1: Các thông số ban đầu của từng mô hình

Model	Accuracy	F1-Score	ROC_AUC
Logistic Regression	0.8103±0.0309	0.7397±0.0515	0.8632±0.0493
Random Forest	0.8114±0.0175	0.7186±0.0348	0.8661±0.0440
XGBoost	0.8148±0.0321	0.7314±0.0566	nan
Support Vector Machine	0.8260±0.0249	0.7447±0.0443	0.8660±0.0389

Với kết quả trên, có thể nhận thấy rằng mô hình **Support Vector Machine (SVM)** đã thể hiện hiệu suất tốt nhất trong lần thử nghiệm đầu tiên, vượt trội hơn so với các mô hình còn lại ở cả chỉ số **Accuracy (0.8260)** và **F1-Score (0.7447)**. Điều này cho thấy SVM có khả năng cân bằng tốt giữa độ chính xác tổng thể và khả năng nhận diện đúng các trường hợp thuộc lớp dương (*positive class*). Với lần thử đầu tiên này đã cho kết quả khi thử nghiệm trực tiếp trên tập test.csv là **0.77511**:

 submission.csv Complete · 6d ago · SVM	0.77511
--	----------------

Tuy nhiên, cần lưu ý rằng *sự chênh lệch giữa các mô hình chưa quá lớn*, đặc biệt giữa Logistic Regression, Random Forest và SVM, điều này cho thấy *việc xử lý dữ liệu ở mức cơ bản vẫn giúp các mô hình đạt được hiệu suất khá ổn định*. Mặc dù vậy, giá trị *ROC-AUC* của các mô hình đều nằm trong khoảng từ 0.86 trở lên, chứng tỏ *khả năng phân biệt giữa hai lớp của các mô hình là tương đối tốt*, tức là các mô hình đều có năng lực dự đoán xác suất hợp lý.

Tuy nhiên, chỉ với những *đặc trưng cơ bản* được giữ nguyên từ dữ liệu đầu vào ban đầu thì *vẫn chưa đủ để mô hình học máy có thể khai thác hết các mối quan hệ tiềm ẩn trong dữ liệu*. Những đặc trưng như *Age*, *Fare*, *Pclass* hay *Sex* tuy mang thông tin quan trọng, nhưng vẫn còn hạn chế trong việc phản ánh đầy đủ các yếu tố ảnh hưởng đến khả năng sống sót của hành khách. Do đó, trong *thí nghiệm tiếp theo*, tôi sẽ *bổ sung thêm một số đặc trưng mới* nhằm tăng khả năng khái quát của mô hình. Cụ thể, sẽ bổ sung các đặc trưng *Title* (được trích từ cột *Name*, lấy phần đầu trong tên, biểu thị của danh xưng), *familySize* (số người thân đi cùng được tính từ 2 nguồn thông tin là *SibSp* và *Parch*). Những đặc trưng này giúp mô

hình nắm bắt được các thông tin xã hội và cấu trúc gia đình, có thể ảnh hưởng đáng kể đến khả năng sống sót.

Bảng 2: Các thông số sau khi thêm Title và familySize

Model	Accuracy	F1-Score	ROC_AUC
Logistic Regression	0.8282±0.0222	0.7659±0.0353	0.8754±0.0349
Random Forest	0.8305±0.0240	0.7633±0.0419	0.8753±0.0428
XGBoost	0.8249±0.0249	0.7601±0.0402	Nan
Support Vector Machine	0.8327±0.0193	0.7569±0.0404	0.8617±0.0373

Mặc dù việc bổ sung các đặc trưng như *Title* và *familySize* đã cải thiện các chỉ số đánh giá trên tập huấn luyện và tập kiểm tra (như độ chính xác, F1-score...), kết quả trên *tập dữ liệu submit thực tế* lại không cải thiện mà thậm chí có phần giảm nhẹ. Hiện tượng này phản ánh *vấn đề overfitting*: các đặc trưng mới giúp mô hình khớp tốt hơn với dữ liệu huấn luyện, nhưng lại không tổng quát hóa tốt trên dữ liệu chưa thấy trước.

 submission.csv Complete - 2d ago	0.77272
--	---------

Cụ thể, các đặc trưng *Title* và *familySize* chứa thông tin giá trị, nhưng đồng thời cũng có thể *tăng mức độ phức tạp của mô hình*, khiến mô hình học các chi tiết đặc thù của tập huấn luyện mà không phản ánh chính xác xu hướng tổng quát của dữ liệu thực tế. Ví dụ, một số danh xưng ít phổ biến hoặc các trường hợp gia đình đặc biệt trong tập huấn luyện có thể chi phối quyết định dự đoán, nhưng trong tập submit lại xuất hiện khác biệt, dẫn đến giảm điểm hiệu năng.

Để tiếp tục cải thiện hiệu suất của mô hình, trong lần thử nghiệm tiếp theo, chúng tôi đã bổ sung thêm hai đặc trưng mới là *IsChild* và *IsMother*. *IsChild* là biến nhị phân thể hiện hành khách có phải là trẻ em hay không, dựa vào tuổi. Đặc trưng này giúp mô hình nhận diện những hành khách có khả năng được ưu tiên cứu hộ cao hơn. Còn *IsMother* biến nhị phân biểu thị hành khách là mẹ, được xác định dựa trên giới tính nữ, tuổi lớn hơn 18, và có ít nhất một con đi cùng (*Parch* > 0). Đặc trưng này nhằm nắm bắt thông tin xã hội quan trọng, bởi các nghiên cứu và dữ liệu thực tế cho thấy các bà mẹ thường có tỷ lệ sống sót cao hơn do ưu tiên cứu hộ.

Việc bổ sung hai đặc trưng này nhằm cung cấp thêm *thông tin ngữ cảnh xã hội và vai trò cá nhân* của hành khách, mà các đặc trưng trước đó như *Title* hay *familySize* chưa thể hiện đầy đủ. Trên lý thuyết, những biến này có khả năng giúp mô hình *nhận diện các*

nhóm hành khách dễ tổn thương hoặc được ưu tiên cứu hộ, từ đó cải thiện độ chính xác dự đoán khả năng sống sót.

Bảng 3: Các thông số sau khi thêm IsChild và IsMother

Model	Accuracy	F1-Score	ROC_AUC
Logistic Regression	0.8294±0.0227	0.7671±0.0358	0.8744±0.0349
Random Forest	0.8305±0.0240	0.7646±0.0435	0.8721±0.0417
XGBoost	0.8226±0.0331	0.7557±0.0497	nan
Support Vector Machine	0.8282±0.0216	0.7527±0.0435	0.8608±0.0393

Kết quả thực nghiệm cho thấy việc bổ sung các đặc trưng *IsChild* và *IsMother* đã giúp độ chính xác trung bình của mô hình tăng khoảng 5% – 6% so với thí nghiệm trước. Điều này cho thấy mô hình không chỉ được cải thiện về khả năng nhận diện các mẫu dữ liệu đặc trưng hơn, mà còn phản ánh tốt hơn mối quan hệ giữa độ tuổi, vai trò xã hội và khả năng sống sót của hành khách.

 submission.csv Complete - 2d ago	0.78229
--	---------

Dựa trên những kinh nghiệm thu được từ các thí nghiệm trước, tôi nhận thấy rằng các đặc trưng liên quan đến vị trí khoang tàu có thể cung cấp thêm thông tin quan trọng giúp mô hình dự đoán tốt hơn. Vì vậy, trong thí nghiệm tiếp theo, tôi sẽ bổ sung hai đặc trưng mới là *HasCabin* và *Deck*. *HasCabin* là đặc trưng nhị phân, cho biết hành khách có thông tin về Cabin hay không, nhằm phản ánh gián tiếp mức độ và điều kiện hạng vé. *Deck* được trích xuất từ ký tự đầu của mã Cabin, thể hiện tầng hoặc khu vực trong tàu mà hành khách ở, có thể liên quan đến khả năng tiếp cận khu vực cứu hộ trong tình huống khẩn cấp.

Việc thêm hai đặc trưng này kỳ vọng sẽ giúp mô hình khai thác tốt hơn các yếu tố không gian trong dữ liệu và tăng khả năng tổng quát hóa trên tập kiểm tra thực tế.

Bảng 4: Các thông số sau khi thêm HasBin và Deck

Model	Accuracy	F1-Score	ROC_AUC
Logistic Regression	0.8294±0.0286	0.7712±0.0398	0.8760±0.0369
Random Forest	0.8271±0.0217	0.7612±0.0400	0.8684±0.0462
XGBoost	0.8282±0.0324	0.7663±0.0533	nan
Support Vector Machine	0.8305±0.0251	0.7625±0.0428	0.8711±0.0427

Kết quả ở Bảng 4 cho thấy việc bổ sung hai đặc trưng *HasCabin* và *Deck* đã mang lại *sự cải thiện nhẹ về hiệu suất mô hình* so với các thí nghiệm trước. Độ chính xác (Accuracy) của các mô hình dao động quanh mức **0.82–0.83**, cùng với kết quả trên tập test tăng lên **0,78708**. Điều này cho thấy các đặc trưng liên quan đến **thông tin vị trí khoang tàu** vẫn có giá trị nhất định trong việc hỗ trợ mô hình nhận diện khả năng sống sót của hành khách.



submission.csv
Complete · 2d ago

0.78708

Tuy nhiên, mức tăng hiệu năng nhìn chung *không quá đáng kể*, nguyên nhân có thể xuất phát từ việc *dữ liệu Cabin bị thiếu nhiều giá trị*, dẫn đến thông tin của hai đặc trưng này chưa được mô hình khai thác đầy đủ.

Nhìn chung, kết quả thí nghiệm này cho thấy việc khai thác *các yếu tố không gian (vị trí khoang tàu)* giúp mô hình có thêm góc nhìn mới, nhưng để đạt được mức cải thiện đáng kể hơn, cần kết hợp với *các kỹ thuật xử lý dữ liệu thiếu (missing data imputation)* hoặc *tạo đặc trưng phức hợp (feature engineering)* trong các bước tiếp theo.

Đối với các giá trị bị thiếu trong dữ liệu, tôi áp dụng *kỹ thuật bổ sung dữ liệu thiếu (missing data imputation)* dựa trên giá trị *trung vị (median)* theo từng nhóm đặc trưng có liên quan. Cụ thể, đối với biến *Fare*, các giá trị còn thiếu được thay thế bằng *trung vị giá vé trong từng nhóm hạng vé (Pclass)*, nhằm phản ánh hợp lý hơn sự khác biệt về mức giá giữa các hạng. Tương tự, đối với biến *Age*, các giá trị thiếu được điền bằng *trung vị tuổi của nhóm hành khách có cùng giới tính (Sex), hạng vé (Pclass) và danh xưng (Title)*. Cách tiếp cận này giúp quá trình ước lượng tuổi trở nên chính xác hơn, vì nó tận dụng được mối quan hệ giữa độ tuổi với các yếu tố xã hội và kinh tế của hành khách.

Cùng với đó tôi kết hợp áp dụng kỹ thuật tạo đặc trưng phức hợp để bổ sung thêm đặc trưng *Age*Pclass* và *Fare_Pclass*. Cụ thể, đặc trưng *Fare_Pclass* được tính bằng cách *chia giá vé (Fare) cho hạng vé (Pclass)*, thể hiện *mức chi trả tương đối của hành khách so với hạng vé mà họ thuộc về*, qua đó phản ánh khả năng chi trả và điều kiện kinh tế của từng nhóm hành khách.

Bên cạnh đó, đặc trưng *Age*Pclass* được xây dựng bằng *tích giữa tuổi (Age) và hạng vé (Pclass)*, nhằm mô hình hóa *mối tương quan kết hợp giữa độ tuổi và điều kiện xã hội*. Đặc trưng này giúp mô hình nhận diện được những khác biệt tiềm ẩn giữa các nhóm hành khách, ví dụ như người trẻ ở hạng cao có khả năng sống sót khác so với người lớn tuổi ở hạng thấp.

Bảng 5: Các thông số sau khi thêm Age*Pclass và Fare_Pclass

Model	Accuracy	F1-Score	ROC_AUC
Logistic Regression	0.8260±0.0240	0.7676±0.0342	0.8753±0.0382
Random Forest	0.8282±0.0312	0.7552±0.0530	0.8703±0.0465
XGBoost	0.8249±0.0340	0.7638±0.0568	nan
Support Vector Machine	0.8327±0.0260	0.7598±0.0478	0.8725±0.0382

Với lần thử nghiệm này tuy kết quả vẫn là **0.78708** nhưng các chỉ số *Accuracy*, *F1-Score* và *ROC_AUC* đã ổn định hơn lần thử nghiệm trước đó. Cũng giống các lần trước, SVM vẫn là mô hình thể hiện tốt nhất khả năng tổng quát với độ chính xác đạt **0.8327±0.0260**, cho thấy mối tương quan giữa hạng vé với tuổi và giá vé vẫn giúp mô hình khai thác được hiệu quả hơn.

 submission.csv Complete - 2d ago	0.78708
---	---------

Với lần thử nghiệm cuối cùng này, chúng tôi sẽ bổ sung thêm 1 đặc trưng mà tôi nghĩ sẽ giúp cải thiện đáng kể cho hiệu suất của mô hình là *TicketPrefix*. Đặc trưng này được tạo ra do trích từ tiền tố của trường dữ liệu *Ticket*. Việc trích xuất này cho phép chuyển đổi *thuộc tính dạng hỗn hợp (chữ và số)* thành thuộc tính phân loại có ý nghĩa thống kê, giúp mô hình học máy nhận biết được các nhóm vé có cùng định dạng hoặc đặc trưng *phát hành tương đồng*, qua đó góp phần cải thiện khả năng phân biệt giữa các nhóm hành khách khác nhau.

Bảng 6: Các thông số sau khi thêm TicketPrefix

Model	Accuracy	F1-Score	ROC_AUC
Logistic Regression	0.8192±0.0338	0.7568±0.0479	0.8750±0.0377
Random Forest	0.8260±0.0301	0.7528±0.0511	0.8703±0.0452
XGBoost	0.8215±0.0318	0.7580±0.0517	nan
Support Vector Machine	0.8350±0.0227	0.7652±0.0406	0.8727±0.0339

Với lần thử nghiệm cuối cùng và bổ sung đặc trưng *TicketPrefix* đã giúp mô hình cải thiện rất tốt với chỉ số vượt trội các lần trước, trong đó SVM vẫn là mô hình dẫn đầu với

hiệu suất cao nhất với *Accuracy* là **0.8350±0.0227** và *F1-Score* là **0.7652±0.0406**, cao nhất trong tất cả mô hình và các lần thử nghiệm.

Đặc trưng *TicketPrefix* đã góp phần cung cấp thêm thông tin về *nguồn gốc hoặc nhóm phát hành vé*, qua đó giúp mô hình nhận biết tốt hơn sự khác biệt giữa các nhóm hành khách. Điều này phản ánh rằng yếu tố hành chính – tổ chức (được mã hóa gián tiếp trong tiền tố vé) có thể có mối liên hệ nhất định với khả năng sống sót của hành khách.

 submission.csv Complete · 6d ago · SVM	0.79425
---	---------

Ngoài việc tối ưu mô hình thông qua chuẩn hoá và kết hợp đặc trưng (feature engineering), chúng tôi cũng tiến hành điều chỉnh siêu tham số (hyperparameter tuning) để cải thiện hiệu suất dự đoán. Tuy nhiên, kết quả cho thấy bộ tham số tối ưu hoá trên tập huấn luyện (train set) lại cho điểm số thấp hơn đáng kể khi nộp lên Kaggle so với bộ tham số mặc định ban đầu. Điều này cho thấy mô hình có thể đã học quá kỹ các đặc trưng trên tập huấn luyện, dẫn đến hiện tượng **overfitting**, làm giảm hiệu suất trên tập kiểm tra thực tế (test set).

```
Đang chạy GridSearchCV cho Random Forest ...
Fitting 10 folds for each of 324 candidates, totalling 3240 fits
Random Forest - Best Params: {'model__max_depth': None, 'model__max_features': 'sqrt', 'model__min_samples_leaf': 2, 'model__min_samples_split': 2, 'model__n_estimators': 500}
Best ROC AUC: 0.8867

Đang chạy GridSearchCV cho SVM ...
Fitting 10 folds for each of 90 candidates, totalling 900 fits
SVM - Best Params: {'model__C': 1.0, 'model__degree': 2, 'model__gamma': 0.1, 'model__kernel': 'rbf'}
Best ROC AUC: 0.8742
```

Bộ tham số sau khi tối ưu của hai mô hình Random Forest và SVM

 notebook853d92a3fd - Version 2 Complete · 4d ago · Grid Search SVM Version 2	0.77990
---	---------

Cụ thể, sau khi áp dụng kỹ thuật tối ưu siêu tham số cho hai mô hình Random Forest và SVM, kết quả trên tập kiểm tra test.csv suy giảm rõ rệt so với mô hình sử dụng tham số mặc định. Điều này cho thấy, dù có vẻ đạt kết quả tốt hơn trên tập train/validation, nhưng mô hình tối ưu lại không tổng quát hoá tốt trên dữ liệu mới. Đây là một minh chứng điển hình cho việc tối ưu hoá quá mức (over-tuning) dẫn đến hiệu suất thực tế giảm.

Tổng thể, các kết quả sau quá trình cải tiến cho thấy việc thiết kế và bổ sung đặc trưng (feature engineering) đóng vai trò then chốt trong việc nâng cao hiệu quả của mô hình học máy. Trong số các mô hình được thử nghiệm, SVM đạt hiệu suất tốt nhất, thể hiện khả năng xử lý linh hoạt các đặc trưng phức tạp và phi tuyến trong dữ liệu thực tế. Điều này cho

thấy rằng, đối với các bài toán có cấu trúc dữ liệu tương đồng, SVM là một lựa chọn đáng tin cậy, đặc biệt khi được kết hợp với chiến lược trích chọn và xây dựng đặc trưng phù hợp.

4. Kết luận

Mặc dù nghiên cứu phải đối mặt với nhiều thách thức trong quá trình xử lý dữ liệu và lựa chọn đặc trưng, những nỗ lực không ngừng của nhóm nghiên cứu đã mang lại những kết quả khả quan. Các mô hình học máy được áp dụng đã chứng minh được hiệu quả trong việc dự đoán khả năng sống sót của hành khách, đặc biệt là mô hình *Support Vector Machine (SVM)*, vốn đạt được độ chính xác và tính ổn định cao hơn so với các phương pháp khác.

Kết quả chi tiết trong nghiên cứu cho thấy việc kết hợp các bước tiền xử lý dữ liệu, chuẩn hóa đặc trưng và tối ưu tham số đã giúp nâng cao đáng kể hiệu suất của mô hình SVM, khẳng định tính phù hợp của thuật toán này trong các bài toán phân loại dữ liệu dạng bảng. Trong tương lai, nhóm nghiên cứu dự kiến sẽ mở rộng quy mô dữ liệu và thử nghiệm thêm các kỹ thuật học máy tiên tiến khác như *Gradient Boosting* hoặc *XGBoost*, nhằm tiếp tục cải thiện độ chính xác và khả năng tổng quát hóa của mô hình trong dự đoán khả năng sống sót trên tàu Titanic.

References

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). "Scikit-learn: Machine learning in Python." *Journal of Machine Learning Research*, 12, 2825-2830.

Altman, N. S. (1992). "An introduction to kernel and nearest-neighbor nonparametric regression." *The American Statistician*, 46(3), 175-185.

Heaton, J. (2017). "An empirical analysis of feature engineering for predictive modeling." *Proceedings of the 14th International Conference on Machine Learning and Data Mining in Pattern Recognition*, 1-13.

Nguyen_Quoc_Huy. "ICIT24_Fraud_Detect_Paper": Addressing data imbalance in insurance fraud prediction using sampling techniques and robust losses".

Ahmed, M., Mahmood, A., & Afzal, S. (2019). "Comparative Analysis of Machine Learning Algorithms for Titanic Survival Prediction." *International Journal of Advanced Computer Science and Applications*, 10(1), 70-75.

Breiman, L. (2001). "Random Forests." *Machine Learning*, 45(1), 5-32